

Constat préalable au fine-tuning médical

Groupe 13 – Jin Alexandre, Richard Antoine, Arthur Fabien, Fouquet Julien, Denieul Matthieu, Garcia Gabriel

Projet	TechCorp Industries — Challenge IA 7h
Filière	IA — Mission Expérimentale (fine-tuning LoRA médical)
Objet du document	Audit des ressources héritées avant lancement du fine-tuning
Constat principal	Absence de dataset médical dans les fichiers hérités du repository

1. Contexte

Avant de lancer le fine-tuning LoRA du modèle médical expérimental, une vérification des ressources héritées de l'équipe précédente a été effectuée, conformément à la démarche de validation de l'intégrité de l'héritage demandée pour l'ensemble du projet. Cette vérification portait sur deux éléments : la documentation méthodologique (`medical_project/Readme.md`) et la présence effective d'un dataset médical exploitable dans le repository.

2. Documentation méthodologique héritée

Le fichier `medical_project/Readme.md` a été inspecté. Son contenu est sain : il s'agit d'un document pédagogique générique présentant les enjeux du fine-tuning médical (terminologie spécialisée, sécurité patient), les modèles recommandés (Phi-3.5 Instruct, Llama 3.1/3.2, Mistral, BioGPT), les datasets publics usuels (PubMedQA, MedQA, BioASQ, MIMIC-III), ainsi que les techniques d'optimisation recommandées (QLoRA, PEFT, bitsandbytes).

Limite identifiée : ce document reste théorique et ne fournit ni notebook, ni script, ni configuration d'entraînement prête à l'emploi. Il ne référence pas non plus explicitement le dataset annoncé par le brief du challenge (`ruslanmv/ai-medical-chatbot` sur Hugging Face). La mise en œuvre du pipeline de fine-tuning a donc dû être construite intégralement par l'équipe IA, en s'appuyant sur les recommandations générales du document.

3. Audit du contenu de datasets/

Le dossier `datasets/` du repository contient deux fichiers, dont les noms suggèrent un lien avec le projet financier :

Fichier	Taille	Contenu constaté
<code>finance_dataset_final.json</code>	2 997 entrées	Conforme à son nom — instructions et réponses financières (politique monétaire, taux d'intérêt, obligations)
<code>test_dataset_16000.json</code>	16 000 entrées	Nom trompeur — contenu hétérogène sans rapport avec la finance (voir détail ci-dessous)

Anomalie — `test_dataset_16000.json`

L'inspection du contenu de ce fichier révèle un mélange hétéroclite de sujets sans rapport avec la finance ni avec le médical : des questions d'histoire générale (montée de l'URSS, chute du rideau de fer), des conseils bancaires génériques, et même du code source Solidity pour un smart contract de trading crypto avec effet de levier (fonction `tradePositionWith0xV2`).

```
{ "instruction": "Compare and contrast the rise of the Soviet Union  
and the fall of the Iron Curtain.", "output": "..."}  
  
{ "instruction": "You are tasked with creating a smart contract  
function that executes a 0x trade using loaned funds...",  
  "output": "```solidity pragma solidity 0.4.24; ..."}
```

Ce fichier s'apparente à un dataset générique d'instruction-tuning multi-domaines (type "Alpaca"), lement mal nommé ou déposé par erreur dans ce repository. Il n'est ni malveillant ni dangereux dans son contenu, mais son nom (`test_dataset_16000.json`) est trompeur et pourrait induire en erreur quiconque l'utiliserait en pensant obtenir un dataset financier ou médical de test. Ce point a été signalé pour suite à donner par l'équipe DATA / CYBER. Ce fichier n'a pas été utilisé pour les besoins du fine-tuning médical.

4. Conclusion et décision retenue

Constat : aucun dataset médical n'est présent dans les fichiers hérités de l'équipe précédente, que ce soit dans `datasets/` ou dans `medical_project/`. Seule la documentation théorique a été transmise.

Décision retenue : conformément à la ressource explicitement indiquée dans le brief du challenge ("Dataset Médical : huggingface.co/datasets/ruslanmv/ai-medical-chatbot"), le dataset médical utilisé pour le fine-tuning LoRA sera chargé directement depuis Hugging Face au sein du notebook Colab, via la bibliothèque `datasets` (`load_dataset("ruslanmv/ai-medical-chatbot")`), sans dépendance à un fichier local du repository.

Cette approche permet de poursuivre la mission expérimentale sans être bloqué par l'absence de ressource locale, tout en s'appuyant sur une source publique de provenance connue et documentée dans le brief officiel du projet.