

TechCorp Industries — Challenge IA

Documentation de déploiement

Filière INFRA — Architecture du système

Projet	TechCorp Industries — Challenge IA 7h
Filière	INFRA — L'Architecte du Système
Objectif	Déployer un serveur d'inférence opérationnel pour Phi-3.5-Financial et le rendre accessible à l'équip
Solution retenue	Ollama
Statut	Complet — serveur opérationnel et documenté

1. Choix technique

Trois options étaient proposées par le brief pour le serveur d'inférence : **Ollama**, **Triton Inference Server**, ou un **serveur maison** (FastAPI / Flask / vLLM). Le choix s'est porté sur **Ollama**.

Ce choix se justifie par trois facteurs principaux, dans le contexte d'un hackathon de 7 heures où le temps constitue la contrainte dominante :

- **Rapidité de mise en service** — installation et démarrage quasi immédiats, sans configuration de bas niveau, contrairement à Triton qui nécessite la définition manuelle d'un dépôt de modèles et d'une configuration de backend.
- **Gestion native du modèle** — Ollama gère lui-même le téléchargement, le chargement en mémoire et la quantization des modèles, réduisant fortement le risque d'erreur de configuration manuelle.
- **Intégration simplifiée** — l'API REST standardisée d'Ollama (/api/generate, /api/chat) facilite l'intégration côté DEV WEB, qui n'a besoin que d'un client HTTP simple pour communiquer avec le serveur.

2. Audit préalable du Modelfile hérité

Avant toute exécution, le fichier ollama_server/Modelfile laissé par l'équipe précédente a été inspecté manuellement, dans une logique de précaution liée au contexte du projet (licenciement de l'équipe précédente pour soupçon de compromission du code et des données).

L'inspection a porté sur la directive FROM, susceptible de pointer vers une source de modèle non fiable, ainsi que sur le contenu du bloc SYSTEM, susceptible de contenir des instructions cachées ou un comportement détourné (prompt injection).

Résultat de l'audit : le fichier s'est révélé sain. La directive FROM phi3.5 référence le modèle officiel et public de la bibliothèque Ollama. Le prompt système définit un rôle cohérent et légitime — un assistant spécialisé en finance pour les analystes de TechCorp Industries. Aucune anomalie n'a été détectée à ce stade.

3. Configuration et optimisation des paramètres d'inférence

Le Modelfile hérité contenait un commentaire # TODO laissant les paramètres d'inférence à compléter. Les valeurs suivantes ont été définies et appliquées :

Paramètre	Valeur	Justification
temperature	0.3	Réponses factuelles et stables, cohérentes avec un usage financier où la précision prime s
top_p	0.9	Restreint la génération à un noyau de tokens probables, limitant les dérives incohérentes
num_predict	512	Plafonne la longueur des réponses pour garantir un temps de réponse acceptable sans tron
repeat_penalty	1.1	Limite les répétitions de formulations dans les réponses longues

Le modèle a ensuite été créé à partir du Modelfile complété, via la commande :

```
ollama create phi3.5-financial -f ollama_server/Modelfile
```

4. Quantization et caractéristiques du modèle

Le modèle déployé utilise une quantization **Q4_0** (4 bits), appliquée automatiquement par Ollama lors du téléchargement du modèle de base phi3.5. Cette quantization réduit la précision des poids du modèle (de 16/32 bits à 4 bits), diminuant fortement l'empreinte mémoire et accélérant l'inférence sur CPU, au prix d'une perte de précision généralement négligeable pour un cas d'usage conversationnel standard.

Ce choix n'a nécessité aucune configuration manuelle : Ollama applique cette quantization par défaut pour la quasi-totalité des modèles de sa bibliothèque, ce qui en fait une optimisation immédiate pour l'usage visé.

Caractéristiques techniques confirmées (ollama show phi3.5-financial)

Architecture	Phi-3
Paramètres	3.8 milliards
Longueur de contexte	131 072 tokens
Dimension d'embedding	3072
Quantization	Q4_0 (4 bits)
Licence	MIT (Microsoft Corporation)

La longueur de contexte de 131 072 tokens constitue un avantage notable pour le cas d'usage visé : elle permet de maintenir un historique de conversation long sans perte de contexte, pertinent pour des échanges approfondis avec les analystes financiers.

Les tokens de fin de séquence (stop) sont correctement configurés (<| system |>, <| user |>, <| end |>, <| assistant |>), garantissant que le modèle respecte la structure du format de chat Phi-3 sans générer de texte parasite au-delà de sa réponse.

5. Incident technique rencontré et résolution

Lors de la première tentative de génération, le serveur retournait systématiquement l'erreur suivante, accompagnée d'une fermeture brutale de la connexion :

```
Error: Post "http://127.0.0.1:11434/api/generate": read tcp
127.0.0.1:xxxx->127.0.0.1:11434: wsarecv: An existing connection
was forcibly closed by the remote host.
```

Chaque tentative de relance via `ollama run` provoquait en outre l'apparition d'instances Ollama supplémentaires en arrière-plan, sans que le service réponde correctement.

Diagnostic : l'analyse du journal serveur (`server.log`) a permis d'identifier la cause exacte — un crash mémoire de bas niveau (`Exception 0xc0000005`, violation d'accès) survenant au chargement du moteur d'inférence (`dyn_llama_server_init`), imputable à un défaut connu de la version d'Ollama installée (0.1.28), une version ancienne datant du début de l'année 2024.

Résolution : désinstallation complète d'Ollama suivie d'une réinstallation en version 0.30. Après cette mise à jour, le modèle `phi3.5-financial` a démarré et répondu sans erreur, de façon stable et cohérente.

6. Validation fonctionnelle

Un test direct en ligne de commande a confirmé le bon fonctionnement du serveur :

```
ollama run phi3.5-financial "What is compound interest?"
```

Le modèle a produit une réponse pertinente, structurée et correcte sur le plan du contenu financier, confirmant l'opérationnalité du déploiement.

7. Accessibilité réseau

Le serveur écoute par défaut sur `127.0.0.1:11434` (localhost uniquement). Cette configuration a été conservée telle quelle, l'équipe DEV WEB opérant sur la même machine et accédant directement au serveur via la variable `OLLAMA_URL=http://localhost:11434`.

Remarque de sécurité, transmise à l'équipe CYBER : une exposition du serveur au réseau local via `OLLAMA_HOST=0.0.0.0:11434` ouvrirait l'API à l'ensemble des machines du LAN sans aucune authentification. Cette configuration n'a pas été activée dans le cadre de ce déploiement, mais constitue un point de vigilance à documenter si elle devait être envisagée.

8. Statut final

- ✓ Serveur d'inférence opérationnel avec Phi-3.5-Financial — déployé, testé, paramétré (temperature, top_p, num)
- ✓ Documentation de déploiement complète — choix technique justifié, étapes détaillées, incident technique docu