

Documentation de déploiement

Groupe 13 – Jin Alexandre, Richard Antoine, Arthur Fabien, Fouquet Julien, Denieul Matthieu, Garcia Gabriel

Projet	TechCorp Industries — Challenge IA 7h
Filière	INFRA — L'Architecte du Système
Objectif	Déployer un serveur d'inférence opérationnel pour Phi-3.5-Financial et le rendre accessible à l'équipe
Solution retenue	Ollama
Statut	Complet — serveur opérationnel et documenté

1. Choix technique

Trois options étaient proposées par le brief pour le serveur d'inférence : **Ollama**, **Triton Inference Server**, ou un **serveur maison** (FastAPI / Flask / vLLM). Le choix s'est porté sur **Ollama**.

Ce choix se justifie par trois facteurs principaux, dans le contexte d'un hackathon de 7 heures où le temps constitue la contrainte dominante :

- Rapidité de mise en service** — installation et démarrage quasi immédiats, sans configuration de bas niveau, contrairement à Triton qui nécessite la définition manuelle d'un dépôt de modèles et d'une configuration de backend.
- Gestion native du modèle** — Ollama gère lui-même le téléchargement, le chargement en mémoire et la quantization des modèles, réduisant fortement le risque d'erreur de configuration manuelle.
- Intégration simplifiée** — l'API REST standardisée d'Ollama (/api/generate, /api/chat) facilite l'intégration côté DEV WEB, qui n'a besoin que d'un client HTTP simple pour communiquer avec le serveur.

2. Audit préalable du Modelfile hérité

Avant toute exécution, le fichier `ollama_server/Modelfile` laissé par l'équipe précédente a été inspecté manuellement, dans une logique de précaution liée au contexte du projet (licenciement de l'équipe précédente pour soupçon de compromission du code et des données).

L'inspection a porté sur la directive `FROM`, susceptible de pointer vers une source de modèle non fiable, ainsi que sur le contenu du bloc `SYSTEM`, susceptible de contenir des instructions cachées ou un comportement détourné (prompt injection).

Résultat de l'audit : le fichier s'est révélé sain. La directive `FROM phi3.5` référence le modèle officiel et public de la bibliothèque Ollama. Le prompt système définit un rôle cohérent et légitime — un assistant spécialisé en finance pour les analystes de TechCorp Industries. Aucune anomalie n'a été détectée à ce stade.

3. Configuration et optimisation des paramètres d'inférence

Le Modelfile hérité contenait un commentaire `# TODO` laissant les paramètres d'inférence à compléter. Les valeurs suivantes ont été définies et appliquées :

Paramètre	Valeur	Justification
<code>temperature</code>	0.3	Réponses factuelles et stables, cohérentes avec un usage financier où la précision prime sur la créativité
<code>top_p</code>	0.9	Restreint la génération à un noyau de tokens probables, limitant les dérivés incohérents
<code>num_predict</code>	512	Plafonne la longueur des réponses pour garantir un temps de réponse acceptable sans tronquer les explications utiles
<code>repeat_penalty</code>	1.1	Limite les répétitions de formulations dans les réponses longues

Le modèle a ensuite été créé à partir du Modelfile complété, via la commande :

```
ollama create phi3.5-financial -f ollama_server/Modelfile
```

4. Quantization et caractéristiques du modèle

Le modèle déployé utilise une quantization **Q4_0** (4 bits), appliquée automatiquement par Ollama lors du téléchargement du modèle de base `phi3.5`. Cette quantization réduit la précision des poids du modèle (de 16/32 bits à 4 bits), diminuant fortement l'empreinte mémoire et accélérant l'inférence sur CPU, au prix d'une perte de précision généralement négligeable pour un cas d'usage conversationnel standard.

Ce choix n'a nécessité aucune configuration manuelle : Ollama applique cette quantization par défaut pour la quasi-totalité des modèles de sa bibliothèque, ce qui en fait une optimisation immédiate pour l'usage visé.

Caractéristiques techniques confirmées (ollama show phi3.5-financial)

Architecture	Phi-3
Paramètres	3.8 milliards
Longueur de contexte	131 072 tokens
Dimension d'embedding	3072
Quantization	Q4_0 (4 bits)
Licence	MIT (Microsoft Corporation)

La longueur de contexte de 131 072 tokens constitue un avantage notable pour le cas d'usage visé : elle permet de maintenir un historique de conversation long sans perte de contexte, pertinent pour des échanges approfondis avec les analystes financiers.

Les tokens de fin de séquence (`stop`) sont correctement configurés (`<|system|>`, `<|user|>`, `<|end|>`, `<|assistant|>`), garantissant que le modèle respecte la structure du format de chat Phi-3 sans générer de texte parasite au-delà de sa réponse.

5. Incident technique rencontré et résolution

Lors de la première tentative de génération, le serveur retournait systématiquement l'erreur suivante, accompagnée d'une fermeture brutale de la connexion :

```
Error: Post "http://127.0.0.1:11434/api/generate": read tcp
127.0.0.1:xxxxx->127.0.0.1:11434: wsarecv: An existing connection
was forcibly closed by the remote host.
```

Chaque tentative de relance via `ollama run` provoquait en outre l'apparition d'instances Ollama supplémentaires en arrière-plan, sans que le service réponde correctement.

Diagnostic : l'analyse du journal serveur (`server.log`) a permis d'identifier la cause exacte — un crash mémoire de bas niveau (`Exception 0xc0000005`, violation d'accès) survenant au chargement du moteur d'inférence (`dyn_llama_server_init`), imputable à un défaut connu de la version d'Ollama installée (0.1.28), une version ancienne datant du début de l'année 2024.

Résolution : désinstallation complète d'Ollama suivie d'une réinstallation en version 0.30. Après cette mise à jour, le modèle `phi3.5-financial` a démarré et répondu sans erreur, de façon stable et cohérente.

6. Validation fonctionnelle

Un test direct en ligne de commande a confirmé le bon fonctionnement du serveur :

```
ollama run phi3.5-financial "What is compound interest?"
```

Le modèle a produit une réponse pertinente, structurée et correcte sur le plan du contenu financier, confirmant l'opérationnalité du déploiement.

7. Accessibilité réseau

Le serveur écoute par défaut sur `127.0.0.1:11434` (localhost uniquement). Cette configuration a été conservée telle quelle, l'équipe DEV WEB opérant sur la même machine et accédant directement au serveur via la variable `OLLAMA_URL=http://localhost:11434`.

Remarque de sécurité, transmise à l'équipe CYBER : une exposition du serveur au réseau local via `OLLAMA_HOST=0.0.0.0:11434` ouvrirait l'API à l'ensemble des machines du LAN sans aucune authentification. Cette configuration n'a pas été activée dans le cadre de ce déploiement, mais constitue un point de vigilance à documenter si elle devait être envisagée.

8. Statut final

- ✓ Serveur d'inférence opérationnel avec Phi-3.5-Financial — déployé, testé, paramétré (temperature, top_p, num_predict, repeat_penalty), quantisé (Q4_0).
- ✓ Documentation de déploiement complète
choix technique justifié, étapes détaillées, incident technique documenté et résolu, accessibilité réseau précisée.